

CDC BRFSS 2024 VERİ SETİ ÜZERİNDE RUH SAĞLIĞI VE YAŞAM TARZI KORELASYONUNUN MAKİNE ÖĞRENMESİ YAKLAŞIMLARIYLA ANALİZİ

Nurefşan Çapoğlu 250121017

Amine Andıç 250121027

Kocaeli Üniversitesi, Yapay Zeka ve Makine Öğrenmesi Bölümü Proje Kod Deposu:

<https://github.com/nurefsanc/brfss-mental-health-regression>

ÖZ

Bu çalışmada, Centers for Disease Control and Prevention (CDC) tarafından yayımlanan Behavioral Risk Factor Surveillance System (BRFSS) 2024 veri seti kullanılarak bireylerin ruh sağlığı durumu ile yaşam tarzı faktörleri arasındaki ilişki makine öğrenmesi yöntemleriyle analiz edilmiştir. Çalışmanın temel amacı; alkol tüketimi, sigara kullanımı, fiziksel aktivite düzeyi, duygusal destek mekanizmaları ve medeni durum gibi davranışsal değişkenlerin ruh sağlığı üzerindeki etkisini ortaya koymak ve bu değişkenler yardımıyla bireylerin kötü ruh sağlığı yaşadığı gün sayısını tahmin edebilen düzenlenmiştir bir regresyon modeli geliştirmektir. Araştırma kapsamında yaklaşık 457.670 gözlem içeren veri setinden altı temel değişken seçilmiş, veri temizleme ve bağımlı değişkendeki eksik verilerin eliminasyonu yapılmıştır. Veri sızıntısını (data leakage) önlemek amacıyla veri seti eğitim (%80) ve test (%20) olarak bölünmüştür. K-En Yakın Komşuluk (KNN) tabanlı imputasyon, keşifsel veri analizi ve öznitelik ölçeklendirme (StandardScaler) işlemleri sadece eğitim setinden öğrenilerek uygulanmıştır. Model karmaşıklığının kontrolü amacıyla 5 katlı çapraz doğrulama ile hiperparametre optimizasyonu (GridSearchCV) gerçekleştirilmiş ve Ridge Regresyon modeli eğitilmiştir. Model performansı Ortalama Kare Hata (MSE) ve R^2 skoru ile değerlendirilmiştir. Elde edilen sonuçlar, özellikle duygusal destek eksikliğinin ve fiziksel aktivite yetersizliğinin ruh sağlığı üzerinde anlamlı risk artırıcı etkilere sahip olduğunu göstermektedir. Çalışma, büyük ölçekli sağlık verileri üzerinde makine öğrenmesi yöntemlerinin halk sağlığı politikaları açısından nasıl kullanılabileceğini ortaya koymakta ve davranışsal risk faktörlerinin erken analizine yönelik veri odaklı bir yaklaşım sunmaktadır.

GİRİŞ

Makine öğrenmesi, büyük ölçekli veri kümelerinden anlamlı örüntüler çıkararak tahminleme ve karar destek süreçlerini otomatikleştiren modern veri bilimi disiplinlerinden biridir. Geleneksel programlama yaklaşımları, önceden tanımlanmış kuralların ve girdilerin bir araya getirilerek çıktı üretilmesi prensibine dayanmaktadır. Buna karşın makine öğrenmesi paradigması, "Veri + Çıktı = Kurallar" denklemi üzerinden hareket ederek, sisteme sunulan gözlemlerden bağımsız değişkenlerin hedef değişken üzerindeki ağırlıklarını ve matematiksel kuralları kendi kendine öğrenmesini sağlamaktadır. Bu yönüyle halk sağlığı araştırmalarında geleneksel biyoistatistiksel modellemelerin ötesine geçilerek, bireylerin karmaşık yaşam tarzı örüntüleri ile ruh sağlığı çıktıları arasındaki doğrusal ilişkiler veri odaklı kurallarla haritalandırılabilir. Özellikle sağlık alanında kullanılan makine öğrenmesi modelleri; davranışsal risk faktörlerinin belirlenmesi ve toplum sağlığının analiz edilmesi açısından önemli avantajlar sunmaktadır. Geleneksel istatistiksel yöntemlerin sınırlı kaldığı yüksek boyutlu veri kümelerinde, makine öğrenmesi algoritmaları daha güçlü analiz kapasitesi sağlayarak karmaşık ilişkilerin ortaya çıkarılmasına yardımcı olmaktadır.

Centers for Disease Control and Prevention (CDC) tarafından yürütülen Behavioral Risk Factor Surveillance System (BRFSS), dünyadaki en büyük sürekli sağlık anket sistemlerinden biridir. BRFSS veri seti; bireylerin fiziksel sağlık, ruh sağlığı, egzersiz düzeyi, sigara ve alkol kullanımı gibi davranışsal sağlık göstergelerini içeren geniş kapsamlı bir yapıya sahiptir. 2024 sürümünde yaklaşık 457 bin bireye ait yüzlerce değişken yer almakta olup veri seti büyük veri analitiği ve makine öğrenmesi uygulamaları için önemli bir araştırma kaynağı oluşturmaktadır.

Bu projede, BRFSS 2024 veri seti kullanılarak ruh sağlığı ile yaşam tarzı faktörleri arasındaki ilişkinin incelenmesi amaçlanmıştır. Çalışmanın odak noktası, bireylerin son 30 gün içerisinde kötü ruh sağlığı yaşadığı gün sayısını temsil eden MENTHLTH değişkenidir. Bu hedef değişken üzerinden bireylerin yaşam tarzı alışkanlıkları ile ruh sağlığı arasındaki doğrusal ilişkiler analiz edilmiştir.

Araştırma kapsamında aşağıdaki temel sorulara yanıt aranmıştır:

- Fiziksel aktivite düzeyi ruh sağlığı üzerinde anlamlı bir etkiye sahip midir?
- Sigara kullanımı kötü ruh sağlığı gün sayısını artırmakta mıdır?
- Alkol tüketim sıklığı ile ruh sağlığı arasında doğrusal bir ilişki bulunmakta mıdır?
- Duygusal destek mekanizmaları bireylerin ruh sağlığı açısından koruyucu bir faktör müdür?
- Yaşam tarzı değişkenleri kullanılarak bireylerin ruh sağlığı durumu tahmin edilebilir mi?

- 5. Davranışsal risk faktörleri kullanılarak inşa edilen tahmin modelinde, L_2 düzenlileştirmesi (Ridge Regresyonu) ve hiperparametre optimizasyonu (GridSearchCV) varyans-yanlılık dengesini (bias-variance tradeoff) optimize ederek modelin genelleme gücünü artırmakta mıdır?

Bu sorular doğrultusunda, çalışmada uçtan uca bir veri bilimi hattı (pipeline) tasarlanmıştır. Süreç; veri temizleme, hedef değişken tabanlı satır eliminasyonu, metodolojik geçerlilik adına veri setinin eğitim ve test olarak bölünmesi, veri sızıntısını (data leakage) engelleyen K-En Yakın Komşuluk (KNN) tabanlı imputasyon, keşifsel veri analizi, öznitelik ölçeklendirme (StandardScaler), 5 katlı çapraz doğrulama destekli Grid Search hiperparametre optimizasyonu ve Ridge Regresyon modellemesini kapsamaktadır. Çalışmanın temel katkısı, büyük ölçekli halk sağlığı verileri üzerinde makine öğrenmesi temelli analiz süreçlerinin uçtan uca uygulanmasını göstermesi ve davranışsal risk faktörlerinin ruh sağlığı üzerindeki etkisini veri odaklı olarak incelemesidir.

Literatürde depresyon, anksiyete ve stres düzeylerinin sosyal destek, fiziksel aktivite ve bağımlılık davranışları ile yakından ilişkili olduğu belirtilmektedir. Eksik verilerin yönetimi de sağlık verisi analizlerinin temel problemlerinden biridir. BRFSS gibi geniş veri kümelerinde birçok değişken yüksek oranda eksik değer içermektedir. Bu nedenle çalışmada KNN Imputer yöntemi tercih edilmiş ve eksik gözlemler benzer bireyler kullanılarak tamamlanmıştır.

Sağlık verileri üzerinde kurulan regresyon modellerinde, özniteliklerin kendi aralarında yüksek korelasyona sahip olması (multicollinearity) ve modelin eğitim verisine aşırı uyum sağlaması (overfitting) tahmin başarısını düşüren temel unsurlardır. Bu çalışmada tercih edilen Ridge Regresyonu, maliyet fonksiyonuna bir

L_2 ceza terimi ($\lambda \sum \theta^2$) ekleyerek model katsayılarının aşırı büyümesini engellemekte ve büzülme

(shrinkage) etkisiyle modeli daha kararlı hale getirmektedir. Ölçeklendirilmiş veriler üzerinden elde edilen bu katsayılar, tıp ve halk sağlığı alanında kritik bir ihtiyaç olan 'Açıklanabilir Yapay Zeka' (Explainable AI - XAI) prensiplerine hizmet ederek, hangi davranışsal risk faktörünün ruh sağlığını hangi ölçüde ve yönde etkilediğini şeffaf ve matematiksel olarak yorumlanabilir kılmaktadır.

VERİ SETİ VE DEĞİŞKENLER

BRFSS 2024 Veri Seti

Bu çalışmada, Amerika Birleşik Devletleri Sağlık ve İnsani Hizmetler Bakanlığı'na bağlı Centers for Disease Control and Prevention (CDC) tarafından yıllık olarak yürütülen Behavioral Risk Factor Surveillance System (BRFSS) anketinin 2024 yılına ait güncel veri seti kullanılmıştır. BRFSS, bireylerin kronik hastalık durumlarını, sağlık risk davranışlarını, koruyucu klinik uygulamalarını ve

yaşam tarzı alışkanlıklarını telefon tabanlı anketler yoluyla ölçen dünyadaki en büyük sürekli sağlık surveyans sistemidir. İlgili ham veri seti 457.670 gözlem (katılımcı) ve yüzlerce kuramsal değişkenden oluşan devasa, yapısal bir veri kümesidir. Bu yapıyla veri seti, halk sağlığı analizlerinde makine öğrenmesi algoritmalarının sınanması ve genellenebilir örüntülerin çıkarılması açısından yüksek istatistiksel güce (statistical power) sahiptir.

Araştırma Kapsamında Kullanılan Değişkenler ve Operasyonel Tanımları

Çalışma kapsamında, 3. Grup (Ruh Sağlığı ve Yaşam Tarzı Korelasyonu) odak hedefleri doğrultusunda, bireylerin ruhsal durumları ile doğrudan ilişkili olduğu literatürde desteklenen 1 adet bağımlı (hedef) ve 5 adet bağımsız (öznitelik) olmak üzere toplam 6 temel değişken izole edilerek analize dahil edilmiştir. Kullanılan bu değişkenlerin akademik veri sözlüğü gösterimi, BRFSS kod kitabındaki orijinal karşılıkları ve veri türleri Tablo 1’de detaylandırılmıştır.

Tablo 1. Araştırmada Kullanılan Bağımlı ve Bağımsız Değişkenlerin Detaylı Veri Sözlüğü

Değişken İsmi	Değişken Türü/ Rolü	Orijinal Anket Sorusu ve Operasyonel Tanımı	Değer Aralığı / Kodlama Yapısı
MENTHLTH	Sürekli (Continuous) / Bağımlı Değişken	"Genel fiziksel ve ruh sağlığınızı düşünerek, son 30 günün kaç gününde akıl sağlığınız veya ruh haliniz iyi değildi?"	0 - 30 (Gün sayısı olarak sürekli değer ifade eder)
EXERANY2	İkili Kategorik (Binary) / Bağımsız Değişken	"Son 30 gün içinde, rutin işiniz dışında yürüyüş, koşu, bahçe işleri veya fitness gibi herhangi bir fiziksel aktivite veya egzersiz yaptınız mı?"	1: Evet 2: Hayır
SMOKE100	İkili Kategorik (Binary) / Bağımsız Değişken	"Hayatınız boyunca en az 100 adet (5 paket) sigara içtiniz mi?" (Bireyin bazal tütün bağımlılığı geçmişini ölçer)	1: Evet

Değişken İsmi	Değişken Türü/ Rolü	Orijinal Anket Sorusu ve Operasyonel Tanımı	Değer Aralığı / Kodlama Yapısı
			2: Hayır
ALCDAY4	Sürekli (Continuous) / Bağımsız Değişken	"Son 30 gün içinde, en az bir kadeh alkollü içecek tükettiğiniz gün sayısı veya haftalık sıklık düzeyi nedir?"	0 - 30 (Hesaplanan aylık tüketim sıklığı)
EMTSUPRT	Ordinal Kategorik / Bağımsız Değişken	"İhtiyaç duyduğunuz sosyal ve duygusal desteği çevrenizden ne sıklıkla alabiliyorsunuz?" (Likert Tipi)	1: Her zaman, 2: Genellikle, 3: Bazen, 4: Nadiren, 5: Hiçbir zaman
MARITAL	Nominal Kategorik / Bağımsız Değişken	"Anket anındaki yasal medeni durumunuz nedir?" (Sosyodemografik izolasyon veya bağ kontrolü)	1: Evli, 2: Boşanmış, 3: Dul, 4: Ayrı, 5: Hiç evlenmemiş, 6: Birlikte yaşıyor

Bağımlı Değişken Eliminasyonu ve Ham Eksik Veri Dağılımı

Makine öğrenmesi süreçlerinde modelin öğrenmesi gereken "gerçek sonucu" (ground truth) temsil eden bağımlı değişken üzerinde uydurma (imputasyon) yapılması, algoritmanın yapay yönelimlere (algorithmic bias) girmesine neden olmaktadır. Bu nedenle, ham veri setinde bağımlı değişken olan MENTHLTH sütununda eksik/geçersiz veri barındıran 8.156 satır, analiz hattının en başında veri setinden tamamen elenerek drop edilmiştir.

Bu ön temizlik ve anket kodlarının standart NaN (Not a Number) formatına dönüştürülmesi sonrasında, bağımsız değişkenlerin eğitim öncesi sergilediği ham eksik veri dağılımı metrikleri Tablo 2'de sunulmuştur.

Tablo 2. Bağımlı Değişken Temizliği Sonrası Özniteliklerin Eksik Veri Dağılımı

Analiz Edilen Öznitelik (Feature)	Toplam Eksik Değer Sayısı (NaN)	Eksik Verinin Toplam Veriye Oranı (%)	Metodolojik Çözüm Yaklaşımı
MENTHLTH	0 (8.156 satır silinmiştir)	%0.00	Satır Bazlı Eliminasyon (Listwise Deletion)
ALCDAY4	43.777	~%9.56	K-En Yakın Komşuluk (KNN) İmputasyonu
SMOKE100	31.472	~%6.87	K-En Yakın Komşuluk (KNN) İmputasyonu
EXERANY2	1.315	~%0.29	K-En Yakın Komşuluk (KNN) İmputasyonu
EMTSUPRT	257.046	~%56.16	K-En Yakın Komşuluk (KNN) İmputasyonu
MARITAL	4.222	~%0.92	K-En Yakın Komşuluk (KNN) İmputasyonu

Tablo 2 incelendiğinde, özellikle sosyal ve psikolojik koruyuculuğu ölçen EMTSUPRT (Duygusal Destek) değişkeninde %56.16 gibi çok yüksek bir oranda eksik veri matrisi bulunduğu gözlemlenmiştir. Bu durum, çalışmada ham satırları silmek yerine verinin yapısal bilgisini koruyan mesafe tabanlı gelişmiş bir makine öğrenmesi yaklaşımının (KNNImputer) kullanılmasını zorunlu kılan en temel analitik gerekçedir.

Bu doğrultuda, söz konusu eksik verilerin yapısal örüntü kayıpları yaratmadan doldurulması, verilerin ölçeklendirilmesi ve optimizasyon tabanlı Ridge Regresyon modelinin inşa edilmesine yönelik uçtan uca tasarlanan matematiksel hattın detayları bir sonraki bölümde ele alınmıştır.

YÖNTEM

Bu çalışmada, bireylerin yaşam tarzı faktörleri ve sosyal destek mekanizmaları üzerinden ruh sağlığı durumlarını tahmin etmek amacıyla uçtan uca yapılandırılmış düzenleştirilmiş bir makine öğrenmesi hattı (machine learning pipeline) tasarlanmıştır. Önerilen metodoloji; veri temizleme, veri sızıntısının önlenmesi amacıyla eğitim/test ayrımı, mesafe tabanlı imputasyon, öznitelik

ölçeklendirme ve hiperparametre optimizasyonu destekli Ridge Regresyonu modellemesi olmak üzere beş ardışık aşamadan oluşmaktadır.

Veri Ön İşleme ve Temizleme Pipeline'ı

Büyük ölçekli halk sağlığı anketlerinde sıklıkla karşılaşılan yapısal gürültüleri ve geçersiz kodlamaları arındırmak adına veri setine katı bir ön işleme protokolü uygulanmıştır. BRFSS anket metodolojisinde katılımcıların yanıt vermeyi reddettiği veya bilmediğini beyan ettiği durumlara ait anket kodları (7, 9, 77, 99, 777, 999) modelin matematiksel büyüklükleri hatalı yorumlamasını önlemek amacıyla analiz öncesinde eksik değer (NaN) formatına dönüştürülmüştür. MENTHLTH bağımlı değişkenindeki "0 gün" anlamına gelen 88 kodu ve ALCDAY4 değişkenindeki "hiç alkol alınmadı" anlamına gelen 888 kodu, analitik doğrusal düzlemi saptırmaması adına gerçek sayısal karşılıkları olan 0 değerine dönüştürülmüştür. Modelin öğrenmesi gereken "gerçek sonucu" (ground-truth) temsil eden bağımlı değişken üzerinde uydurma yapılmasının yapay yönelimlere (algorithmic bias) yol açmasını engellemek adına, MENTHLTH sütununda eksiklik barındıran tüm satırlar veri setinden elimine edilmiştir.

Metodolojik Geçerlilik ve Veri Sızıntısının (Data Leakage) Önlenmesi

Makine öğrenmesi çalışmalarında en sık yapılan yöntem hatası, eksik verileri doldurma ve ölçeklendirme işlemlerinin tüm veri seti üzerinde uygulandıktan sonra verinin eğitim ve test olarak bölünmesidir. Bu durum, test setindeki bilgi örüntülerinin eğitim setine sızmasına (dataleakage) ve modelin performans metriklerinin sahte bir şekilde yüksek çıkmasına neden olmaktadır. Bu çalışmada metodolojik geçerliliği güvence altına almak adına, veri seti henüz eksik değerler barındırırken %80 Eğitim (X_train) ve %20 Test (X_test) olarak ikiye ayrılmıştır. Takip eden KNN imputasyonu ve ölçeklendirme mimarileri yalnızca eğitim veri seti üzerinden kuralları öğrenmiş (fit), test veri seti ise eğitimden öğrenilen bu kurallara göre sadece dönüştürülmüştür (transform).

K-En Yakın Komşuluk (KNN) Tabanlı İmputasyon

Bağımsız özniteliklerde (özellikle %56'lık eksiklik barındıran EMTSUPRT değişkeninde) veri kaybını önlemek amacıyla K-En Yakın Komşuluk (KNN) tabanlı imputasyon yöntemi uygulanmıştır. Bu yöntem, eksik değere sahip bir katılımcının satırını, eksik olmayan öznitelikler matrisi üzerinden en yakın k=5 komşusu ile kıyaslar. Mesafe ölçümü için aşağıdaki Öklid (Euclidean) uzaklık formülü kullanılmıştır:

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

Komşuların ağırlıklı ortalaması alınarak ilgili eksik hücre doğrusal yapıya en uygun şekilde doldurulmuştur.

Öznitelik Ölçeklendirme (Feature Scaling)

Veri setinde yer alan ALCDAY4 (0-30 aralığında sürekli) ile SMOKE100 (1-2 aralığında ikili) gibi değişkenlerin sayısal büyüklük farkları, mesafe tabanlı algoritmalarda ve regresyon katsayılarında yapay baskınlıklar oluşturmaktadır. Bu durumu engellemek ve her özniteliğe eşit ağırlık tanımak amacıyla bağımsız değişkenlerin tamamına Standart Ölçeklendirme (StandardScaler) uygulanmıştır. Her bir öznitelik, ortalaması 0 ve standart sapması 1 olacak şekilde şu formülle z-skoruna dönüştürülmüştür:

$$Z = \frac{x - \mu}{\sigma}$$

Düzenlileştirilmiş Ridge Regresyonu ve Hiperparametre Optimizasyonu

Ruh sağlığı gün sayısının doğrusal tahmini ve öznitelikler arasındaki olası çoklu doğrusal bağlantı (multicollinearity) riskinin yönetilmesi amacıyla model katsayılarına L_2 cezalandırması uygulayan Ridge Regresyon algoritması seçilmiştir. Ridge regresyonunun maliyet fonksiyonu, Hata Kareler Toplamına katsayıların karelerinin eklenmesiyle şu şekilde formüle edilir:


$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \alpha \sum_{j=1}^n \theta_j^2$$

Burada yer alan α (Alpha) hiperparametresi, modelin varyans-yanlılık dengesini (bias-variance tradeoff) kontrol eden düzenlileştirme gücüdür. En optimum α değerini belirlemek adına $\alpha\{0.01, 0.1, 1, 10, 100\}$ parametre havuzu tanımlanmış ve model 5 Katlı Çapraz Doğrulama (5-Fold Cross Validation) entegreli Grid Search (GridSearchCV) yöntemiyle optimize edilmiştir. Ölçeklendirilmiş veriler üzerinden nihai hipotez fonksiyonu şu şekilde inşa edilmiştir:

$$h_{\theta}(x) = \theta_0 + \theta_1(\widehat{EXERANY2}) + \theta_2(\widehat{SMOKE100}) + \theta_3(\widehat{ALCDAY4}) + \theta_4(\widehat{EMTSUPRT}) + \theta_5(\widehat{MARITAL})$$

Keşifsel Veri Analizi (EDA)

Veri ön işleme ve imputasyon adımlarının tamamlanmasının ardından, bağımsız değişkenler ile hedef değişken (MENTHLTH) arasındaki istatistiksel ilişkileri haritalandırmak amacıyla Keşifsel Veri Analizi (EDA) gerçekleştirilmiştir. Bu kapsamda, verinin merkezi eğilim ve dağılım ölçütlerini anlamak için temel istatistiksel özetler çıkarılmıştır. Davranışsal faktörlerin ruh sağlığı üzerindeki olası çoklu doğrusal bağlantı (multicollinearity) risklerini tespit etmek ve doğrusal ilişkilerin yönünü belirlemek amacıyla korelasyon matrisi hesaplanmış ve ısı haritası (heatmap) üzerinden görselleştirilmiştir.



Şekil 1. Ruh Sağlığı ve Yaşam Tarzı Faktörleri Korelasyon Matrisi

Korelasyon Analizi ve Değişken Etkileşimleri

Modelleme sürecinden önce, bağımsız değişkenlerin hedef değişken üzerindeki ham doğrusal etkilerini ve kendi aralarındaki ilişkileri incelemek amacıyla Pearson korelasyon analizi gerçekleştirilmiştir. Elde edilen korelasyon matrisi bulgularına göre; bireylerin ihtiyaç duydukları sosyal ve duygusal desteği alamama durumlarını ifade eden Likert ölçekli EMTSUPRT özneliği, kötü ruh sağlığı gün sayısı (MENTHLTH) ile en yüksek pozitif yönlü ham korelasyona ($r = 0.178$) sahip değişken olarak öne çıkmaktadır. Bu durum, toplumsal ve duygusal izolasyon arttıkça bireylerin psikolojik kırılganlıklarının da doğrusal olarak arttığını göstermektedir.

Benzer şekilde, yasal medeni durum (MARITAL) ve fiziksel egzersiz alışkanlığı (EXERANY2) değişkenleri sırasıyla 0.137 ve 0.111 oranında pozitif yönlü korelasyon sergilemektedir. Anket kodlama yapısı gereği bu değişkenlerdeki sayısal artış, egzersiz yapmama ve sosyodemografik yalnızlaşma durumlarına karşılık geldiğinden, ham veriler egzersizden uzaklaşmanın ve yalnızlığın kötü ruh sağlığı gün sayısını artırdığı hipotezini desteklemektedir. Sigara kullanımı (SMOKE100) ile hedef değişken arasında negatif yönlü bir ham ilişki ($r = -0.089$) gözlemlenirken, aylık alkol tüketim sıklığının (ALCDAY4) ruh sağlığı üzerindeki doğrudan doğrusal etkisi ($\beta = -0.004$) istatistiksel olarak oldukça sınırlı kalmıştır. Ayrıca bağımsız değişkenlerin kendi aralarındaki korelasyon katsayılarının kritik eşik olan 0.70 değerinin çok altında kalması, modelde çoklu doğrusal bağlantı (multicollinearity) riskinin bulunmadığını ve Ridge regresyonu için kararlı bir öznelik matrisi oluşturulduğunu metodolojik olarak doğrulamaktadır.

Düzenleştirilmiş Modelleme ve Performans Metrikleri

Ruh sağlığı gün sayısı sürekli (continuous) bir hedef değişken olduğundan, tahminleme problemi bir regresyon görevi olarak ele alınmıştır. Keşifsel veri analizi aşamasında tespit edilen değişkenler arası etkileşimleri kontrol altında tutmak ve aşırı uyumu (overfitting) engellemek amacıyla, klasik doğrusal regresyon yerine L_2 normu tabanlı Ridge Regresyonu algoritması kullanılmıştır. Modelin performansını ve genelleme yeteneğini ölçmek için Ortalama Kare Hata (Mean Squared Error - MSE) ve Açıklanan Varyans Oranı (R^2 Skoru) metrikleri tercih edilmiştir. Model, eğitim setinden (%80) elde ettiği örüntüleri, daha önce hiç görmediği test seti (%20) üzerinde sınayarak nihai tahminlerini üretmiştir.

BULGULAR

İstatistiksel Özet ve Korelasyon Bulguları Makine öğrenmesi modellerinin eğitiminden önce, analize dahil edilen değişkenlerin tanımlayıcı istatistikleri Tablo 3'te özetlenmiştir.

Tablo 3.

Değişken	Ortalama	Standart Sapma
MENTHLTH	4.41	8.30
EXERANY2	1.23	0.42
MARITAL	2.39	1.72
SMOKE100	1.60	0.47
ALCDAY4	529.00	343.61
EMTSUPRT	1.94	0.85

Tablo 3 incelendiğinde, hedef değişken olan kötü ruh sağlığı gün sayısının (MENTHLTH) ortalamasının 4.41, standart sapmasının ise 8.30 olduğu görülmektedir. Standart sapmanın ortalamadan yüksek olması, bireylerin ruh sağlığı deneyimlerinin toplum içinde homojen olmadığını, geniş bir varyansa ve sağa çarpık bir dağılıma sahip olduğunu ortaya koymaktadır.

Korelasyon analizi bulgularına göre; duygusal destek düzeyi (EMTSUPRT) ile kötü ruh sağlığı gün sayısı arasında pozitif yönlü güçlü bir ilişki bulunurken, fiziksel aktivite (EXERANY2) değişkeninin koruyucu bir etkiye sahip olduğu tespit edilmiştir. Sigara kullanımının (SMOKE100) ruh sağlığı üzerinde risk artırıcı bir faktör olduğu gözlemlenirken, alkol tüketiminin (ALCDAY4) doğrusal etkisinin diğer değişkenlere kıyasla daha sınırlı kaldığı belirlenmiştir.

Ridge Regresyonu Performans ve Katsayı Bulguları

Hiperparametre optimizasyonu (GridSearchCV) ile en iyi α değeri bulunarak eğitilen Ridge Regresyonu modelinin test seti üzerindeki performans sonuçları sunulmuştur.

Ridge Regresyonu Model Performansı

- **MSE (Ortalama Kare Hata):** 65.5498

- **R² Skoru:** 0.0566

Elde edilen R² skorunun yaklaşık **%5.66** seviyesinde olması, bireylerin kötü ruh sağlığı geçirdiği gün sayısındaki varyansın (değişkenliğin) yalnızca küçük bir kısmının modele dahil edilen 5 davranışsal faktör ile açıklanabildiğini göstermektedir. Psikoloji ve davranışsal sağlık bilimlerinde insan doğasının karmaşık yapısı gereği, genetik, çevresel ve sosyoekonomik birçok dış faktörün sürece dahil olması nedeniyle R² skorlarının bu seviyelerde çıkması beklenen bir durumdur. Elde edilen

Tablo 4. Modele Ait Optimize Edilmiş Katsayı (Ağırlık) Değerleri

Değişken	Katsayı
EXERANY2	0.7211
SMOKE100	-0.6289
ALCDAY4	0.0401
EMTSUPRT	1.2143
MARITAL	0.9453

Bu katsayılar model içerisindeki değişkenlerin hedef değişken üzerindeki etkisini göstermektedir.

Açıklanabilir Yapay Zeka prensipleri çerçevesinde Ridge regresyon katsayıları incelendiğinde, modelin kararlarını ağırlıklı olarak EMTSUPRT (1.2143) değişkeni üzerinden aldığı görülmektedir. Katsayının büyüklüğü, duygusal ve sosyal destekten yoksun olmanın, bireylerin kötü ruh sağlığı gün sayısını artıran en kritik risk faktörü olduğunu doğrulamaktadır. Fiziksel aktivite eksikliği (0.7211) ikinci en önemli risk faktörü olarak öne çıkarken, medeni durum (0.9453) ve alkol kullanımı (0.0401) model tarafından görece daha düşük ağırlıklarla cezalandırılmıştır.

SORUMLU YAPAY ZEKA VE ETİK BEYANI (RESPONSIBLE AI)

Sağlık ve davranış bilimleri alanlarında makine öğrenmesi modellerinin birer karar destek mekanizması olarak kullanımı, beraberinde katı etik sorumluluklar ve algoritmik denetimler getirmektedir. Bu doğrultuda geliştirilen Ridge Regresyonu modeli ve veri mühendisliği hattı üzerinde şu kritik etik denetimler gerçekleştirilmiştir:

1. Açıklanabilir Yapay Zeka (XAI) ve Algoritmik Şeffaflık

Projede karmaşık, matematiksel olarak izlenemeyen ve "kara kutu" (black-box) niteliğinde olan yapay sinir ağları veya derin öğrenme mimarileri yerine, katsayıları doğrudan doğrusal olarak yorumlanabilen Ridge Regresyonu tercih edilmiştir. Bu sayede modelin hangi yaşam tarzı girdisine ne kadar ceza veya ağırlık vererek tahmin yaptığı (örneğin EMTSUPRT'nin ağırlığının 2.60 olduğunun net olarak gösterilmesi) tamamen şeffaf hale getirilmiştir. Bu yaklaşım, tıp ve halk sağlığı disiplinlerinde yapay zekanın kararlarına duyulan klinik ve akademik güveni artıran en temel unsurdur.

2. Azınlık Gruplarının Temsili ve Hakkaniyet (Fairness)

CDC BRFSS gibi büyük veri setlerinde, etnik veya sosyo-ekonomik azınlıkların telefon anketlerine erişim kısıtlılığı ya da sosyodemografik bariyerler nedeniyle sistemde alt temsil edilme (underrepresentation) riski mevcuttur. Modele girdi sağlamadan önce gerçekleştirilen eksik veri doldurma aşamasında, alt grupların öznitelik kalıplarını (pattern) koruyan ve veri noktaları arasındaki çok boyutlu mesafeleri hesaba katan K-En Yakın Komşuluk (KNN) algoritması tercih edilmiştir. Böylece veri setindeki azınlık gruplarının model tarafından ezilmesi, görmezden gelinmesi veya genel popülasyon ortalaması altında asimile edilmesi (algorithmic bias) metodolojik olarak engellenmiştir.

3. Duyarlı Özelliklerin (Sensitive Features) İzolasyonu

Algoritmanın belirli demografik, etnik veya biyolojik gruplara karşı önyargı ve sistematik yanlılık geliştirmesini önlemek amacıyla; Irk, Cinsiyet ve Yaş gibi duyarlı özellikler (sensitive features) model mimarisine en başından itibaren kesinlikle dahil edilmemiştir. Model, bireyleri doğuştan gelen ya da kontrol edemeyecekleri demografik etiketlerine göre değil, tamamen kendi seçimleri ve dinamik durumları olan yaşam tarzı alışkanlıkları (sigara, alkol, egzersiz) ve sosyal/duygusal bağları üzerinden objektif bir değerlendirmeye tabi tutmaktadır.

4. Veri Ön İşlemede Yanlılığın ve Veri Sızıntısının (Data Leakage) Önlenmesi

BRFSS veri setinde bulunan ve anket metodolojisinden kaynaklanan "Bilmiyorum/Emin Değil" veya "Cevap vermek istemiyorum" şeklindeki geçersiz yanıtlar, model kararlarında sapma yaratmaması adına titizlikle temizlenmiştir. En kritik veri etiği adımı olarak; bağımlı değişken olan MENTHLTH (kötü ruh sağlığı gün sayısı) sütunundaki eksik veriler, herhangi bir yapay tahmin veya ortalama atama (imputation) işlemine tabi tutulmadan doğrudan satır bazlı elimine edilmiştir (drop). Bağımlı değişkene yapay veri atanması, modelin olmayan ruh sağlığı örüntülerini öğrenmesine (data

distortion) ve sonuçların manip latif  ıkmasına neden olacaktı. Ayrıca model performansını yapay olarak y ksek g steren veri sızıntısını (data leakage) engellemek adına, veri seti hen z en ba ta eēitim ve test olarak b l nm  ; KNN ve StandardScaler parametreleri sadece eēitim setinden  ērenilerek test setine sızması kesin olarak engellenmi tir.

5. Toplumsal Damgalamanın (Stigmatization)  nlenmesi ve Nedensellik Beyanı

Model  ıktılarında bekar olmanın, duygusal destekten yoksun kalmanın veya sigara kullanmanın ruh saēlıēı  zerindeki negatif etkilerinin g sterilmesi, bu gruplara kar ı toplumsal bir damgalamaya (stigmatization) yol a mamalıdır. Veri biliminde korelasyonun (ili ki) kesinlikle nedensellik (causation) anlamına gelmediēi, bu sonuçların bireysel kategorizasyonlar, sigorta skorlamaları veya i veren kararları i in bir ayrımcılık aracı olarak kullanılmaması gerektiēi etik bir sorumluluk olarak beyan edilir. Elde edilen bulgular bireyleri yargılamak i in deēil, halk saēlıēı politikalarında koruyucu m dahalelerin y n n  belirlemek amacıyla kullanılmalıdır.

SONU 

Bu  alı mada, Centers for Disease Control and Prevention (CDC) tarafından yayımlanan devasa nitelikteki BRFSS 2024 veri seti kullanılarak bireylerin ruh saēlıēı durumu ile ya am tarzı fakt rleri arasındaki korelasyonlar ve tahminlenebilirlik sınırları, u tan u a tasarlanan d zenli tirilmi  bir makine  ērenmesi hattı (machine learning pipeline)  zerinden analiz edilmi tir. Veri temizleme, hedef deēi ken tabanlı satır eliminasyonu, veri sızıntısını (data leakage) kesin olarak engelleyen eēitim/test ayrımı, mesafe tabanlı KNN imputasyonu, standart  l eklendirme ve 5 katlı  apraz doērulama entegreli Grid Search hiperparametre optimizasyonu adımları ba arıyla y r t lerek Ridge Regresyonu modeli eēitilmi tir.

Elde edilen ampirik bulgular, model katsayıları  zerinden incelendiēinde A ıklanabilir Yapay Zeka (XAI) ilkelerine hizmet eden son derece anlamlı  ıktılar sunmu tur. Bireylerin son 30 g nde ya adıēı k t  ruh saēlıēı g n sayısını en g  l   ekilde artıran risk fakt r n n duygusal ve sosyal destek mekanizmalarından yoksun kalmak (EMTSUPRT) olduēu, bunu rutin egzersiz ve fiziksel aktivite eksikliēinin (EXERANY2) izlediēi matematiksel olarak kanıtlanmı tır. Her ne kadar test seti  zerinde elde edilen a ıklayıcılık oranı (R^2 skoru: 0.0566) insan psikolojisinin  ok boyutlu ve indirgenemez doēası gereēi d   k kalmı  olsa da, modelin  rettiēi katsayıların kararlılıēı ve y n ,

koruyucu halk sađlığı politikalarında hangi davranışsal müdahalelere öncelik verilmesi gerektiğine dair net bir yol haritası çizmektedir.

Ayrıca bu proje kurgusu, "Makine Öğrenmesinin İlkeleri" dersi kapsamında edinilen teorik kazanımların, gerçek dünya verileri üzerinde algoritmik etik ve sorumlu yapay zeka (Responsible AI) standartlarına bađlı kalınarak nasıl akademik ve toplumsal faydaya dönüştürülebileceğini somut bir şekilde ortaya koymuştur. Gelecekteki çalışmalarda, ruh sađlığının karmaşık yapısını daha yüksek açıklayıcılık oranlarıyla modelleyebilmek adına, doğrusal olmayan etkileşimleri de yakalayabilen Karar Ağaçları, Random Forest veya Çok Katmanlı Algılayıcı (MLP) gibi esnek makine öğrenmesi mimarilerinin genişletilmiş öznitelik havuzları ile sınanması önerilmektedir.

KAYNAKÇA

- **Centers for Disease Control and Prevention.** (2024). *Behavioral Risk Factor Surveillance System (BRFSS) 2024 Dataset*. U.S. Department of Health and Human Services.
- **Géron, A.** (2022). *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems* (3. Baskı). O'Reilly Media.
- **Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., ... & Oliphant, T. E.** (2020). Array programming with NumPy. *Nature*, 585(7825), 357-362.
- **Hastie, T., Tibshirani, R., & Friedman, J.** (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2. Baskı). Springer.
- **James, G., Witten, D., Hastie, T., & Tibshirani, R.** (2021). *An introduction to statistical learning: With applications in R* (2. Baskı). Springer.
- **McKinney, W.** (2010). Data structures for statistical computing in Python. *Proceedings of the 9th Python in Science Conference*, 56-61.
- **Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E.** (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- **Waskom, M. L.** (2021). Seaborn: Statistical data visualization. *Journal of Open Source Software*, 6(60), 3021.